

Neurónové siete

prednáška 1

2019/2020 letný semester

Ing. Ján Magyar

čo je umelá inteligencia?

vlastnosť systému, vďaka ktorej je systém schopný vyriešiť úlohy, ktoré by vyriešil človek len so znalosťami

Systemy UI

- schopnosť uložiť znalosti (knowledge representation)
- aplikovať znalosti pre riešenie problému – uvažovanie (reasoning)
- získavať nové znalosti počas experimentov – učenie (learning)

Rozdelenie UI

- klasické prístupy
 - symbolická UI
 - vyžadujú symbolickú reprezentáciu vedomostí
 - sekvenčné spracovanie
 - use case: spracovanie prirodzeného jazyka, plánovanie procesov, atď.
- moderné prístupy
 - nesymbolická UI
 - systém je dynamický
 - use case: rozpoznávanie vzorov, simulácia pamäte, atď.

- neurónové siete sú jeden z moderných prístupov
- inšpirácia prišla zo štruktúry ľudského mozgu
 - $10^{11} - 10^{14}$ neurónov
 - 10^4 synapsií na jeden neurón
 - 4.7 bitov na synapsiu
 - ľudský mozog dokáže ukladať 2.5 petabytov informácií

Umelá neurónová sieť

Neurónová sieť je masívne paralelný procesor, ktorý má sklon k uchovávaní experimentálnych znalostí a ich ďalšieho využívania. Napodobňuje ľudský mozog v dvoch aspektoch:

- poznatky sú zbierané počas učenia
- medzineurónové spojenia sú využívané na ukladanie znalostí

Prečo neurónové siete?

- univerzálny aproximátor funkcií
- ak máme systém, ktorý nevieme analyticky popísať a namodelovať, ale máme informácie o jeho fungovaní, vieme ho namodelovať pomocou neurónovej siete

Štúdia neurónových sietí

- teória NS
 - matematický rozbor NS
 - teoretické rozboru návrhu topológie
- simulácia NS
 - pomocou počítačových systémov
 - cieľom je sieť naučiť na niečo
- implementácia NS
 - implementácia naučenej NS do hardvérovej podoby

Paralelizmus v NS

- neurónové siete sú paralelné výpočtové systémy
- umelý neurón je rýchlejší ako ľudský, ale miera paralelizmu je v mozgu väčšia
- silu neurónovej siete určuje miera paralelizmu

Typy úloh riešiteľných pomocou NS

- aproximácia funkcie
- klasifikácia
- riešenie predikčných problémov
- riadenie procesov
- transformácia signálov
- asociačné problémy

Životný cyklus NS

- označme maticu všetkých synaptických váh ako \mathbf{W}
- potom životný cyklus NS sa delí na:
 - fáza učenia, kde

$$\frac{\partial W}{\partial t} \neq 0$$


- fáza života, kde

$$\frac{\partial W}{\partial t} = 0$$

Základné pojmy trénovania NS

- príznak
- príklad
- príkladový priestor
- reprezentatívna vzorka
- trénovacia vzorka
- testovacia vzorka
- validačná vzorka


Neurón




Prvky neurónu

- vstup (dendrit)
- prah θ_i
- aktivačná funkcia f
- výstupná funkcia o_i
- synaptické váhy
 - excitačné
 - inhibičné

Dopředná NS



Rekurentná NS




Šírenie signálu v NS

- synchronné šírenie signálu – všetky neuróny menia svoj stav do taktu
- sekvenčné – neuróny menia svoj stav postupne pri šírení signálu
- blok-sekvenčné – aktivizujú sa len skupiny neurónov
- asynchrónne – neuróny menia svoje stavy asynchrónne, nezávisle


Perceptrón

- najjednoduchšia neurónová sieť
- pre dichotomickú klasifikáciu
- lineárne separovateľné triedy



Topológia perceptrónu

- senzorová vrstva
- asociatívna vrstva
- výstupný neurón



Vstup a výstup perceptrónu

- vstup

$$in(t) = \sum_{j=1}^n w_j(t)x_j(t) - \theta$$

- výstup

$$ou(t) = \begin{cases} 1 & \text{ak } in(t) \geq 0 \\ 0 & \text{ak } in(t) < 0 \end{cases}$$

- separující nadrovina

$$\sum_{j=1}^n w_j(t)x_j(t) - \theta = 0$$

Učenie perceptrónu

1. inicializácia váh
2. ak vstupný vektor $\mathbf{x}(t)$ je správne klasifikovaný pomocou $\mathbf{w}(t)$, tak

$$\mathbf{w}(t + 1) = \mathbf{w}(t)$$

3. ak vstupný vektor $\mathbf{x}(t)$ bol nesprávne klasifikovaný pomocou $\mathbf{w}(t)$, tak

$$\mathbf{w}(t + 1) = \mathbf{w}(t) - \gamma \mathbf{x}(t)$$

pre **CL2** a

$$\mathbf{w}(t + 1) = \mathbf{w}(t) + \gamma \mathbf{x}(t)$$

pre **CL1**

Veta o konvergencii perceptrónu

Majme trénovaciu množinu vektorov \mathbf{X} , ktoré môžu patriť len do dvoch rôznych tried **CL1** a **CL2**, ktoré sú lineárne separovateľné. Perceptrón po realizovaní k_0 omylov sa určite dostane do stavu, keď nebude meniť svoje synaptické váhy, kedy konverguje. To znamená, že bude spoľahlivo klasifikovať vektory do príslušných tried.

otázky?